

Relazione di Progetto

*Predizione del rischio di diabete
mediante modelli di classificazione*

Studente: Eljihad Youssef

Matricola: 181607

Anno Accademico 2024/2025

Abstract

Il diabete rappresenta una delle principali emergenze sanitarie a livello mondiale, con variabili demografiche, comportamentali e cliniche che ne influenzano il rischio in modo complesso e non lineare.

Questo progetto affronta un **task di classificazione**, confrontando differenti algoritmi per individuare i soggetti a rischio; il modello che dimostrerà la migliore capacità di separare le classi verrà selezionato per la valutazione finale.

1 Introduzione al dataset

Il dataset utilizzato proviene dal CDC Diabetes Health Indicators (UCI ML Repository) ed è stato salvato in formato CSV per facilitarne l'importazione; è reperibile attraverso il link nella sezione "Riferimenti" in fondo a questo report [1].

Il dataset è composto da **253 680** istanze e **22** colonne (di cui 21 feature in input e 1 target binario). Non sono presenti valori mancanti.

La suddivisione scelta è la seguente:


- **Training Set:** 80 %
- **Testing Set:** 20 %

Di seguito vengono elencate le feature e il target del dataset:

- **Diabetes_binary** (output): 0 = no diabete, 1 = rischio diabete
- **HighBP**: pressione alta (0/1)
- **HighChol**: colesterolo alto (0/1)
- **CholCheck**: colesterolo controllato nell'ultimo anno (0/1)
- **BMI**: indice di massa corporea (kg/m^2 , float)

- **Smoker:** fumatore (0/1)
- **Stroke:** pregresso ictus (0/1)
- **HeartDiseaseorAttack:** malattia o attacco cardiaco (0/1)
- **PhysActivity:** attività fisica regolare (0/1)
- **Fruits:** consumo regolare di frutta (0/1)
- **Veggies:** consumo regolare di verdura (0/1)
- **HvyAlcoholConsump:** consumo eccessivo di alcol (0/1)
- **AnyHealthcare:** accesso a servizi sanitari (0/1)
- **NoDocbcCost:** rinuncia a visite per costi (0/1)
- **GenHlth:** salute percepita generale (1=ottima ... 5=scarso)
- **MentHlth:** giorni di cattivo stato mentale (0–30, int)
- **PhysHlth:** giorni di cattivo stato fisico (0–30, int)
- **DiffWalk:** difficoltà a camminare (0/1)
- **Sex:** sesso (0=femminile, 1=maschile)
- **Age:** fascia d'età (1–13, int)
- **Education:** livello di istruzione (1–4, int)
- **Income:** fascia di reddito (1–8, int)

2 Exploratory Data Analysis (EDA)



2.1 Distribuzione di BMI per classe

Figura 1 mostra l'istogramma (con curva KDE) del Body Mass Index (BMI) separato in base alla classe target Diabetes_binary. Si osserva chiaramente che:

- La densità di soggetti **senza diabete** (barra blu, curva verde) è concentrata su valori di BMI compresi tra **22 e 30**.

- La densità di soggetti **a rischio diabete** (barra arancio, curva rossa) si sposta leggermente verso BMI più elevati, con un picco intorno a **28–34**.

Questa differenza suggerisce un'associazione positiva tra un BMI alto e il rischio di diabete, confermando l'importanza di considerare l'indice di massa corporea come una delle feature principali nel nostro modello di classificazione.




Figura 2: nella heatmap delle variabili {BMI, MentHlth, PhysHlth, Age, GenHlth} le correlazioni restano tutte $\leq |0.50|$.

1. **PhysHlth–GenHlth ≈ 0.50** (salute percepita peggiora con più giorni di malessere fisico)
2. **MentHlth–GenHlth ≈ 0.30**
3. **BMI–GenHlth ≈ 0.25**

3 Analisi dei modelli di classificazione utilizzati

In questa sezione confrontiamo **quattro approcci** distinti, articolati in due momenti:

1. **Cross-validation (5-fold)** sul training set per valutare il ROC-AUC di ciascuna pipeline
2. **Valutazione finale** sul test set (80/20 stratificato)

Vengono elencati di seguito i modelli utilizzati:

- **Logistic Regression (baseline)**
Iper-parametri scelti:
`{'solver': 'liblinear', 'penalty': 'l2', 'class_weight': 'balanced'}`
- **Logistic Regression con SMOTE + Selezione L1**
Iper-parametri scelti dalla grid search:
`{'C': 0.1, 'solver': 'liblinear', 'penalty': 'l1', 'class_weight': 'balanced'}`
Tecniche aggiuntive:

SMOTE (Synthetic Minority Oversampling Technique),
Feature selection embedded con SelectFromModel su regressione logistica L1.

- **Random Forest**

Iper-parametri scelti:

`{'n_estimators': 100, 'class_weight': 'balanced', 'random_state': 42}`

- **Voting Ensemble**

Combinazione soft voting dei due modelli migliori:

- Logistic Regression (con SMOTE e selezione L1)
- Random Forest

Modello	Preprocessing	ROC-AUC CV (train)	ROC- AUC Test	Precision ₁	Recall ₁	F1- score ₁
Logistic Regression (baseline)	StandardScaler + class_weight=balanced	0.8233	–	–	–	–
Logistic + SMOTE + L1-selection (C=0.1)	StandardScaler + SMOTE + SelectFromModel(L1)	0.8181	0.8197	0.3094	0.7669	0.4409
Random Forest	StandardScaler + RF (100 alberi, class_weight=balanced)	0.7930	0.7881	0.4534	0.1522	0.2279
Voting Ensemble	Soft-voting tra Logistic L1 e RF	–	0.8187	0.4025	0.4807	0.4381

1. **Logistic baseline** funge da riferimento semplice e mostra un ROC-AUC CV di 0.8233.
2. L'**estensione lineare** con SMOTE e selezione L1 ottiene un ROC-AUC Test di 0.8197, con elevato recall¹ (0.77) a fronte di precision¹ più bassa.
3. La **Random Forest** migliora la precision¹ sui positivi (0.45) ma sacrifica il recall¹ (0.15), con ROC-AUC Test 0.7881.
4. Il **Voting Ensemble** bilancia meglio precision¹ e recall¹, mantenendo un ROC-AUC Test di 0.8187.


Questa comparazione evidenzia come ogni pipeline presenti trade-off diversi tra sensibilità (recall) e precisione nella classe a rischio.

4 Valutazione sul testing set

Di seguito riportiamo le performance dei quattro modelli sul **20 %** dei dati riservati al test.

Modello	Precision ₁	Recall ₁	F1-score ₁	ROC-AUC
Voting Ensemble (soft)	0.4025	0.4807	0.4381	0.8187

Figura 3: Curve ROC sul test set



Commento

1. Il modello **Logistic esteso** ottiene il ROC-AUC più alto e un richiamo elevato, ideale quando l'obiettivo è catturare quanti più veri positivi possibile.
2. La **Random Forest** alza la precisione ma perde sensibilità, captando pochi casi di diabete.
3. Il **Voting Ensemble** offre un buon compromesso, migliorando l'equilibrio tra precisione e richiamo con un F1-score paragonabile al modello lineare.

Riferimento

[1] CDC Diabetes Health Indicators Dataset – UCI Machine Learning Repository.